

Universidad Rafael Landívar

Ciencia de Datos · Segundo semestre 2026

Ing. Max Cerna

# **Proyecto 1 (Fase 1)**

## **Red Metropolitana**

Integrantes:

Yasmely Dubraska Fariñas Aldana 1329223

Jose Rodrigo Herrera Muralles 1042619

Walter José Herrera Salvatierra 1109722

23 de septiembre de 2026

# Resumen

En esta fase armamos el pipeline completo por capas (Bronze → Staging → Silver → Gold) para juntar los datos de los cuatro operadores: Transmetro, Transurbano, MetroRiel y Aerómetro. Usamos las herramientas recomendadas del curso: Kafka para streaming (simulado en desarrollo), carpetas con Parquet para el lake, DuckDB como warehouse, dbt para las transformaciones y Prefect para orquestar.

Los datos son los 9 archivos que genera generar\_red\_metropolitana.py con la configuración por defecto (45 días desde el 1 de junio de 2026, unos 137 MB).

| Qué medimos             | Resultado                                                                     |
|-------------------------|-------------------------------------------------------------------------------|
| Filas ingeridas         | 1,730,184 (todas cuadran archivo = Bronze)                                    |
| Padrón de Transmetro    | 15,611 activas antes de los borrados → 14,834 activas y 2,598 de baja después |
| Usuarios únicos         | TM 43,255 · TU 36,567 · MR 22,885 · AM 14,496                                 |
| Registros en cuarentena | 12,336 (9,707 de operación + 2,629 del CDC)                                   |
| Filas en Gold           | 1,647,569 abordajes y 295,511 trayectos de MetroRiel                          |
| Pruebas de dbt          | 108 de 108 pasan                                                              |
| Idempotencia            | 52 tablas, 0 diferencias entre la corrida 1 y la 2                            |

## Dónde está cada script

| Punto | Script                                                                                                                                            |
|-------|---------------------------------------------------------------------------------------------------------------------------------------------------|
| 1.1   | ingesta/productor.py y consumidor.py (streaming), ingest/batch.py (catálogos, MetroRiel y Transurbano), ingest/cdc.py (CDC)                       |
| 1.2   | dbt/models/cdc/cdc_operaciones.sql, padron_vigente.sql, padron_transmetro_vigente.sql y cat_usuarios_*.sql                                        |
| 1.3   | dbt/models/staging/ y dbt/models/silver/ (silver_zona, silver_identidad_usuario, silver_eventos_evaluados, silver_cuarentena, silver_padron_scd2) |
| 1.4   | docs/1.4-ddl-gold.sql y dbt/models/gold/                                                                                                          |
| 1.5   | flows/pipeline.py (Prefect)                                                                                                                       |

## 1.1 Ingesta y capa Bronze

### Vía de cada archivo

| Archivo                       | Vía                      | Por qué                                               |
|-------------------------------|--------------------------|-------------------------------------------------------|
| transmetro_validaciones.csv   | Streaming (Kafka)        | Cada validación es un evento que llega todo el tiempo |
| aerometro_boardings.csv       | Streaming (Kafka)        | Igual, cada abordaje es un evento suelto              |
| Los 4 catálogos               | Batch                    | Casi nunca cambian                                    |
| metroriel_viajes.jsonl        | Batch                    | MetroRiel entrega el viaje ya cerrado                 |
| cdc_padron_usuarios.csv       | CDC                      | Es lo único que se actualiza y se borra               |
| transurbano_transacciones.csv | Batch (decisión nuestra) | Ver abajo                                             |

El streaming lo hacemos con un productor que publica el CSV línea por línea y un consumidor que lo escribe a Bronze. En desarrollo lo corrimos en modo simulado (el mismo productor y consumidor, pero conectados en memoria), porque no teníamos Docker. El código para Kafka real está listo (docker-compose.yml).

### ¿Por qué Transurbano va por batch?

- **Cada fila es una transacción de cobro, no un abordaje.** Trae un código de estado y 41,390 transacciones (5%) son pagos rechazados (saldo insuficiente o tarjeta inválida). Parece más una exportación del sistema de cobro que un flujo de torniquete.
- **No trae un ID de transacción.** Ojo, no hablamos del ID del usuario (ese sí viene), sino de un identificador de cada transacción. Sin eso no hay una llave para publicar cada mensaje en Kafka ni para detectar si un mensaje llegó dos veces. En batch identificamos el archivo completo por su hash.
- **El formato es de cierre de lote:** fecha y hora en columnas separadas y el monto en centavos.

**Consecuencia de esta decisión:** Transurbano llega con retraso (hasta un día) comparado con Transmetro y Aerómetro, que entran por streaming. Eso quiere decir que su demanda no se puede ver en vivo en el tablero, y que cualquier análisis de transbordo cercano en tiempo real (por ejemplo, alguien que baja del Transmetro y sube a un bus de Transurbano minutos después) queda incompleto hasta que entra la carga batch. Si en el futuro se necesitara en tiempo real, solo hay que cambiar su vía en `ingesta/comun.py`, pero primero habría que pedirle al operador que mande un ID de transacción.

### ¿Bronze vive en el lake o en el warehouse? En el lake

Bronze son carpetas con archivos Parquet:

lake/bronze/fuente=<fuente>/fecha\_ingesta=<fecha>/<hash>.parquet. Lo decidimos así porque:

- **El JSON anidado de MetroRiel se guarda tal cual.** Parquet guarda entry y exit como estructuras anidadas sin aplanarlas, y los viajes sin salida quedan con exit en null.
- **Todo se guarda como texto.** Si viene una fecha mal escrita, Bronze la guarda como llegó y es Silver el que decide si va a cuarentena.
- **No depende del motor.** DuckDB lee el lake directo. Si mañana cambiamos a otro warehouse, Bronze no se toca.
- **Ocupa menos.** Los 136.8 MB crudos quedaron en 31.3 MB en Parquet.

Cada fila lleva la hora de ingesta (\_ingested\_at), el archivo de origen, el hash del archivo y la vía. La partición es por fecha de ingesta.

### Tabla de conteos por archivo

| Archivo                       | Vía       | Filas en archivo | Filas en Bronze  | ¿Cuadra?  |
|-------------------------------|-----------|------------------|------------------|-----------|
| tm_estaciones.csv             | batch     | 104              | 104              | Sí        |
| tu_paradas.csv                | batch     | 328              | 328              | Sí        |
| mr_estaciones.csv             | batch     | 22               | 22               | Sí        |
| am_estaciones.csv             | batch     | 14               | 14               | Sí        |
| metroriel_viajes.jsonl        | batch     | 299,100          | 299,100          | Sí        |
| transurbano_transacciones.csv | batch     | 832,791          | 832,791          | Sí        |
| cdc_padron_usuarios.csv       | cdc       | 31,050           | 31,050           | Sí        |
| transmetro_validaciones.csv   | streaming | 363,221          | 363,221          | Sí        |
| aerometro_boardings.csv       | streaming | 203,554          | 203,554          | Sí        |
| <b>Total</b>                  |           | <b>1,730,184</b> | <b>1,730,184</b> | <b>Sí</b> |

## 1.2 Staging y CDC

Staging es un esquema del warehouse que se borra al inicio de cada corrida (DROP SCHEMA staging) y dbt lo vuelve a llenar desde Bronze. Bronze en cambio nunca se borra, solo crece.

### Hallazgo: el padrón no es solo de Transmetro

En teoría el archivo son los cambios del padrón de Transmetro, pero la columna tarjeta trae cuatro formatos:

| Formato     | Operador    | Operaciones |
|-------------|-------------|-------------|
| TC-00012345 | Transmetro  | 22,326      |
| 0000012345  | Transurbano | 5,223       |
| MR0012345   | MetroRiel   | 1,295       |
| SIN-TARJETA | Ninguno     | 2,206       |

Lo que hicimos: lo tratamos como un registro central de personas donde cada tarjeta guarda de qué operador es, y sacamos aparte el padrón de Transmetro (solo tarjetas TC-), que es lo que pide el enunciado. Las filas SIN-TARJETA van a cuarentena, porque no se sabe de quién son; si las aplicáramos, todas se volverían una sola "tarjeta" que mezclaría a miles de personas.

### Cómo aplicamos el CDC

Las operaciones se aplican en orden de secuencia, tarjeta por tarjeta:

| Operación | Caso                            | Qué hacemos                                                                                                      |
|-----------|---------------------------------|------------------------------------------------------------------------------------------------------------------|
| INSERT    | Tarjeta nueva                   | Queda activa                                                                                                     |
| INSERT    | Tarjeta que estaba de baja      | Se reactiva                                                                                                      |
| UPDATE    | Tarjeta activa                  | Cambia perfil o zona de residencia                                                                               |
| UPDATE    | Primera operación de la tarjeta | La tarjeta ya existía antes del log, se toma como alta                                                           |
| UPDATE    | Tarjeta de baja                 | No se aplica, va a cuarentena (CDC UPDATE SOBRE BAJA)                                                            |
| DELETE    | Cualquiera                      | Baja lógica: activa = false y fecha de baja. La tarjeta NO se borra, así no se pierde el historial de sus viajes |

### Los DELETE sin cuerpo no van a cuarentena

Los DELETE llegan solo con la llave, sin perfil ni zona. Revisamos que eso no los mande a cuarentena por venir incompletos:

- Los 4,050 DELETE del archivo llegan sin cuerpo.
- Se aplicaron 3,772. Para no dejar la fila vacía, el perfil y la zona se copian de la última versión conocida de esa tarjeta.
- Los 278 que quedaron en cuarentena son solo los que traen SIN-TARJETA, o sea que no tienen ninguna llave. Ninguno se rechazó por venir sin cuerpo.
- DELETE con tarjeta válida que no se aplicaron: 0.

### Conteo antes y después de aplicar los borrados

| Métrica                                                   | Valor  |
|-----------------------------------------------------------|--------|
| Operaciones en el log                                     | 31,050 |
| En cuarentena (2,206 SIN-TARJETA + 423 UPDATE sobre baja) | 2,629  |
| Operaciones aplicadas                                     | 28,421 |
| Altas (INSERT)                                            | 10,003 |
| Cambios (UPDATE)                                          | 14,646 |

|                |       |
|----------------|-------|
| Bajas (DELETE) | 3,772 |
| Reactivaciones | 281   |

Por operador de la tarjeta:

| Operador     | Activas ANTES | Activas DESPUÉS | Dadas de baja | Total en padrón |
|--------------|---------------|-----------------|---------------|-----------------|
| Transmetro   | 15,611        | 14,834          | 2,598         | 17,432          |
| Transurbano  | 3,638         | 3,430           | 608           | 4,038           |
| MetroRiel    | 899           | 846             | 146           | 992             |
| <b>Total</b> | <b>20,148</b> | <b>19,110</b>   | <b>3,352</b>  | <b>22,462</b>   |

**Respuesta:** Transmetro: antes de los borrados había 15,611 tarjetas activas. Después quedaron 14,834 activas y 2,598 dadas de baja.

El padrón tiene más tarjetas después de los borrados, no menos. Eso pasa porque hay tarjetas que solo aparecen en un DELETE (ya existían antes de que empezara el log) y quedan registradas de baja. Es la prueba de que el DELETE no borra.

### Usuarios únicos por operador

Transurbano, MetroRiel y Aerómetro no tienen padrón. Para cada uno armamos un catálogo mínimo con las llaves distintas que aparecen en su archivo de operación. Solo tienen una columna (la llave), sin nombre ni fecha de alta ni nada más, porque esos operadores nunca mandaron esa información y no la vamos a inventar.

| Operador    | Archivo                       | Usuarios únicos |
|-------------|-------------------------------|-----------------|
| Transmetro  | transmetro_validaciones.csv   | 43,255          |
| Transurbano | transurbano_transacciones.csv | 36,567          |
| MetroRiel   | metroriel_viajes.jsonl        | 22,885          |
| Aerómetro   | aerometro_boardings.csv       | 14,496          |

Transmetro aparece solo para comparar; él sí tiene padrón.

## 1.3 Capa Silver

### Unificación de formatos

|             | Transmetro             | Transurbano                 | MetroRiel      | Aerómetro  | En Silver                                                              |
|-------------|------------------------|-----------------------------|----------------|------------|------------------------------------------------------------------------|
| Fecha       | YYYY-MM-DD<br>HH:MM:SS | DD/MM/YYYY<br>+ hora aparte | ISO 8601       | ISO en UTC | Timestamp en hora de Guatemala. Aerómetro se pasa de UTC a UTC-6       |
| Dinero      | Quetzales              | Centavos                    | Quetzales      | Quetzales  | Todo en quetzales (Transurbano / 100)                                  |
| Una fila es | Abordaje               | Transacción                 | Viaje completo | Abordaje   | TU: solo estados 1, 2 y 3 son abordajes. MR: la entrada es el abordaje |

### Dimensión zona

Cada fuente escribe la zona distinto (Zona 10, Z10, District 10, MIXCO, Mixco). Hicimos una función que lleva cualquier forma a una sola clave (Z10, MIXCO), sin tildes ni espacios, y la comparamos contra una lista oficial de 26 territorios: las 22 zonas de la capital (no existen la 20, 22 ni 23) y 4 municipios (Mixco, Villa Nueva, San Miguel Petapa y Santa Catarina Pinula). Aparecen 60 valores distintos en las fuentes y los 60 quedaron conformados. El detalle está en entregables/1.3-conformacion-zona.csv.

### Identidad del usuario

No hay una tabla que relacione las cuatro tarjetas, así que cualquier estrategia es una aproximación. La nuestra:

- **TM, TU y MR se unen por el número.** TC-00012345, 0000012345 y MR0012345 se reducen a 12345 y los tomamos como la misma persona. Antes revisamos que el formato sea del operador correcto.
- **Aerómetro no se une.** Su llave es un hash de 12 caracteres que no trae el número de la persona, así que no hay con qué compararlo. Cada hash queda como una persona aparte.
- **No inventamos vínculos.** Lo que no se puede unir se queda solo.
- **Seudonimización antes de Gold.** usuario\_sk = md5(sal secreta + persona). La sal está en el archivo .env, que no se sube al repositorio. Gold nunca ve la tarjeta.

| Sistema     | Llaves distintas | Unidas por número | Sin unir | Usan también otro sistema |
|-------------|------------------|-------------------|----------|---------------------------|
| Transmetro  | 43,257           | 43,257            | 0        | 32,920                    |
| Transurbano | 36,567           | 36,567            | 0        | 30,308                    |
| MetroRiel   | 22,885           | 22,885            | 0        | 20,422                    |
| Aerómetro   | 14,496           | —                 | 14,496   | 0                         |

Resultado: 70,380 personas; 36,829 (52%) usan más de un sistema (26,833 usan dos y 9,996 usan tres). En esta tabla Transmetro tiene 43,257 llaves y no 43,255 como en usuarios únicos, porque aquí también cuentan 2 tarjetas TC- del padrón que nunca viajaron.

**Supuesto:** TM, TU y MR usan la misma numeración de personas, o sea que el mismo número en dos sistemas es la misma persona. Lo apoya el padrón del CDC, que usa la llave de cualquiera de los tres para la misma persona.

## Límites:

- Los usuarios de Aerómetro cuentan como personas separadas. Eso infla el total de personas y esconde parte del transbordo.
- Si dos operadores usaran el mismo número para personas distintas, las uniríamos mal. Sin un padrón común no se puede detectar.
- Si una persona tiene dos tarjetas del mismo sistema, cuenta como dos personas.

Para medir cuánto afecta no unir Aerómetro, probamos unirlo con la regla del hash que aparece en el script generador (una Agencia real no la tendría, por eso no es el resultado oficial). Con eso las personas bajan de 70,380 a 56,848 y los multisistema suben de 36,829 a 41,486. O sea, no unir Aerómetro sobreestima las personas en 24%. Es un buen argumento para pedirle a Aerómetro su regla.

## Reglas de calidad y cuarentena

Los registros malos no se botan: van a la tabla silver\_cuarentena con su motivo, una explicación, el registro original completo y el archivo de donde vino. Cada registro tiene un solo motivo: el de la primera regla que no cumple, en este orden:

| #   | Regla                                      | Cuándo aplica                                                                     |
|-----|--------------------------------------------|-----------------------------------------------------------------------------------|
| 1   | DUPLICADO_REINGESTA                        | El mismo evento llegó en otro archivo                                             |
| 2   | DUPLICADO_TORNIQUETE                       | El mismo evento sale dos veces en el mismo archivo (el torniquete leyó dos veces) |
| 3   | USUARIO_NULO                               | No trae llave de usuario                                                          |
| 4   | PARADA_NULA                                | Código de parada o estación vacío                                                 |
| 5   | ESTACION_DESCONOCIDA                       | La estación no está en el catálogo                                                |
| 6   | FECHA_INVALIDA                             | La fecha no se puede leer                                                         |
| 7   | FECHA_FUTURA                               | La fecha es después de cuando se ingirió el registro                              |
| 8   | VIAJE_SIN_SALIDA                           | Viaje de MetroRiel sin salida (exit en null)                                      |
| 9   | SALIDA_INCONSISTENTE                       | Salida antes de la entrada o en la misma estación                                 |
| 10  | ZONA_INVALIDA                              | La estación no tiene una zona reconocida                                          |
| 11  | MONTO_INVALIDO                             | Monto vacío o negativo                                                            |
| 12  | ESTADO_DESCONOCIDO                         | Estado de Transurbano que no es 1, 2, 3, 7 ni 9                                   |
| CDC | CDC_SIN_TARJETA /<br>CDC_UPDATE_SOBRE_BAJA | Ver sección 1.2                                                                   |

Las transacciones de Transurbano con estado 7 o 9 no son cuarentena: son pagos rechazados que están bien registrados. No cuentan como abordaje, pero las guardamos en silver\_transacciones\_rechazadas\_tu (41,390).

## Conteo de registros por regla

| Fuente       | Regla                 | Registros     | % de la fuente |
|--------------|-----------------------|---------------|----------------|
| Transmetro   | DUPLICADO_TORNIQUETE  | 1,115         | 0.31%          |
| Transurbano  | PARADA_NULA           | 4,189         | 0.50%          |
| Transurbano  | FECHA_FUTURA          | 814           | 0.10%          |
| MetroRiel    | VIAJE_SIN_SALIDA      | 3,589         | 1.20%          |
| CDC          | CDC_SIN_TARJETA       | 2,206         | 7.11%          |
| CDC          | CDC_UPDATE_SOBRE_BAJA | 423           | 1.36%          |
| <b>Total</b> |                       | <b>12,336</b> |                |

Salen justo los cuatro problemas que menciona el enunciado: duplicados de torniquete, paradas nulas, fechas del futuro y viajes sin salida. Aerómetro no tuvo ningún registro malo. Las otras reglas están programadas pero con estos datos no se activaron. En total, los 9,707 registros de operación en cuarentena son el 0.57% de 1,698,666. Duplicados detectados: 1,115 de torniquete y 0 de reingesta.

La tabla de cuarentena completa (12,336 registros con motivo) está en entregables/1.3-cuarentena.csv. Aquí van unos ejemplos:

| Fuente      | Evento         | Motivo                | Detalle                                                                          |
|-------------|----------------|-----------------------|----------------------------------------------------------------------------------|
| CDC         | 1000           | CDC_SIN_TARJETA       | La operación no trae una tarjeta identificable (SIN-TARJETA)                     |
| CDC         | 10088          | CDC_UPDATE_SOBRE_BAJA | UPDATE sobre una tarjeta que ya estaba dada de baja: no se aplica                |
| MetroRiel   | 100046         | VIAJE_SIN_SALIDA      | Viaje de MetroRiel sin validación de salida                                      |
| Transmetro  | 10008          | DUPLICADO_TORNIQUETE  | Lectura repetida: mismo evento dos veces en el mismo archivo (se conserva la pri |
| Transurbano | 0070b737bb0e3d | FECHA_FUTURA          | Fecha 2027-08-17 06:54:16 posterior a la ingesta 2026-09-23 14:31:32.223327      |
| Transurbano | 00005289057eb4 | PARADA_NULA           | Código de estación/parada vacío                                                  |

### No se pierde ningún registro

| Sistema      | Filas en Bronze  | Abordajes limpios | Pagos rechazados | Cuarentena   |
|--------------|------------------|-------------------|------------------|--------------|
| Transmetro   | 363,221          | 362,106           | —                | 1,115        |
| Transurbano  | 832,791          | 786,398           | 41,390           | 5,003        |
| MetroRiel    | 299,100          | 295,511           | —                | 3,589        |
| Aerómetro    | 203,554          | 203,554           | —                | 0            |
| <b>Total</b> | <b>1,698,666</b> | <b>1,647,569</b>  | <b>41,390</b>    | <b>9,707</b> |

Esto lo revisa una prueba de dbt (assert\_ningun\_registro\_se\_pierde) en cada corrida.

### Padrón con SCD Tipo 2

silver\_padron\_scd2 tiene una fila por cada versión de cada tarjeta, con valido\_desde, valido\_hasta (9999-12-31 si está vigente) y es\_vigente. Cada operación aplicada abre una versión nueva y cierra la anterior; el DELETE abre una versión con activa = false. Quedaron 28,421 versiones para 22,462 tarjetas. Con esto se puede saber, por ejemplo, qué perfil tenía una tarjeta el 20 de junio.

## 1.4 Diseño dimensional y capa Gold

### Grano de la tabla principal

**fct\_abordaje: una fila por cada abordaje de un usuario en una estación, de cualquiera de los cuatro sistemas.**

Elegimos el abordaje porque es lo único que registran los cuatro. Si usáramos "viaje puerta a puerta" tendríamos que inventar los viajes de tres sistemas encadenando validaciones, y eso mete supuestos en la tabla principal.

**MetroRiel** de cada viaje de MetroRiel sacamos su abordaje (estación y hora de entrada) y lo metemos en fct\_abordaje, igual que los otros tres. Así la demanda por modo, zona y hora está completa con los cuatro modos (295,511 abordajes de MetroRiel). El viaje completo (salida, duración, estaciones recorridas) no se pierde: va en una segunda tabla de hechos, fct\_trayecto\_metroriel, con su propio grano.


| Sistema      | Filas en fct_abordaje |
|--------------|-----------------------|
| Transmetro   | 362,106               |
| Transurbano  | 786,398               |
| MetroRiel    | 295,511               |
| Aerómetro    | 203,554               |
| <b>Total</b> | <b>1,647,569</b>      |

### Matriz del bus

| Proceso (tabla de hechos)                    | Fecha | Tiempo | Sistema    | Estación           | Zona               | Usuario |
|----------------------------------------------|-------|--------|------------|--------------------|--------------------|---------|
| Abordajes (fct_abordaje)                     | ✓     | ✓      | ✓          | ✓                  | ✓                  | ✓       |
| Trayectos MetroRiel (fct_trayecto_metroriel) | ✓     | ✓      | ✓ (MR)     | ✓ origen y destino | ✓ origen y destino | ✓       |
| Padrón de tarjetas (fct_padron_diario)       | ✓     |        | ✓ operador |                    | ✓ residencia       |         |

Las dimensiones son las mismas tablas para los tres procesos (conformadas): dim\_fecha, dim\_tiempo, dim\_sistema, dim\_estacion, dim\_zona y dim\_usuario.

# Diagrama del modelo



## Dimensión tiempo

- dim\_tiempo tiene grano de hora (8,760 filas para 2026) y se relaciona con dim\_fecha (grano día).
- Hora del día (0 a 23) y franja (madrugada, mañana, tarde, noche).
- Día hábil: lunes a viernes que no sea asueto. En el periodo de los datos cae el 30 de junio (Día del Ejército).
- Hora pico: día hábil y hora entre 6:00 y 8:59 o entre 17:00 y 19:59.

## Clasificación de medidas

| Medida                                                        | Tabla                                   | Tipo         | Por qué                                                           |
|---------------------------------------------------------------|-----------------------------------------|--------------|-------------------------------------------------------------------|
| cantidad_abordajes                                            | fct_abordaje                            | Aditiva      | Se suma por cualquier dimensión                                   |
| monto_q                                                       | fct_abordaje,<br>fct_trayecto_metroriel | Aditiva      | El ingreso se suma por cualquier dimensión                        |
| cantidad_trayectos,<br>duracion_min,<br>estaciones_recorridas | fct_trayecto_metroriel                  | Aditiva      | Se suman (el promedio no)                                         |
| altas_del_dia,<br>bajas_del_dia                               | fct_padron_diario                       | Aditiva      | Son movimientos del día, se suman entre días                      |
| tarjetas_activas                                              | fct_padron_diario                       | Semi-aditiva | Es un saldo: se suma entre zonas u operadores, pero no entre días |

|                                   |           |            |                                                         |
|-----------------------------------|-----------|------------|---------------------------------------------------------|
|                                   |           |            | (19,000 el lunes + 19,000 el martes no son 38,000)      |
| Usuarios distintos                | Calculada | No aditiva | Un usuario que viaja en dos zonas se contaría dos veces |
| Duración promedio, % en hora pico | Calculada | No aditiva | Son cocientes, se recalculan en cada nivel              |

## DDL y filas en Gold

El DDL completo con llaves primarias y foráneas está en docs/1.4-ddl-gold.sql. Lo probamos corriéndolo en una base vacía. Ningún modelo de Gold lee de Bronze: el flujo lo revisa en cada corrida y se detiene si pasa.

| Tabla                  | Filas     |
|------------------------|-----------|
| dim_estacion           | 468       |
| dim_fecha              | 365       |
| dim_sistema            | 4         |
| dim_tiempo             | 8,760     |
| dim_usuario            | 70,380    |
| dim_zona               | 26        |
| fct_abordaje           | 1,647,569 |
| fct_padron_diario      | 8,612     |
| fct_trayecto_metroriel | 295,511   |

dim\_zona ya trae la cobertura: 15 territorios tienen al menos una estación y 11 no tienen servicio de ningún modo (zonas 2, 3, 5, 14, 15, 16, 19, 21, 24 y 25, y Santa Catarina Pinula).

## 1.5 Orquestación e idempotencia

El flujo está en flows/pipeline.py con Prefect: ingesta batch → CDC → streaming → vaciar staging → dbt build (modelos y 108 pruebas) → revisar linaje → contar → exportar entregables.

### Por qué no duplica

- **Bronze:** cada archivo se identifica por su hash. Si ya se cargó, se salta.
- **Kafka:** cada mensaje lleva la llave <hash>:<línea>, así el consumidor ignora los repetidos.
- **Staging:** se borra al inicio de cada corrida.
- **Silver y Gold:** son tablas que dbt reconstruye desde Bronze; mismo Bronze, mismo resultado. FECHA\_FUTURA compara contra la hora de ingesta y no contra la hora actual, para que no cambie entre corridas.

### Evidencia: dos corridas con conteos idénticos

Corrimos el flujo desde cero (2026-09-23 14:32:33), contamos, lo volvimos a correr (2026-09-23 14:33:25) y contamos otra vez. Resultado de herramientas/comparar.py:

### 52 tablas comparadas, 0 diferencias -> IDENTICOS

En la corrida 2 los 9 archivos salen como "ya ingerido, se omite". Algunas tablas:

| Capa    | Tabla                     | Corrida 1 | Corrida 2 | ¿Igual? |
|---------|---------------------------|-----------|-----------|---------|
| bronze  | transmetro_validaciones   | 363,221   | 363,221   | Sí      |
| bronze  | transurbano_transacciones | 832,791   | 832,791   | Sí      |
| bronze  | metroriel_viajes          | 299,100   | 299,100   | Sí      |
| bronze  | aerometro_boardings       | 203,554   | 203,554   | Sí      |
| bronze  | cdc_padron_usuarios       | 31,050    | 31,050    | Sí      |
| control | ingest_log                | 9         | 9         | Sí      |
| silver  | silver_eventos_evaluados  | 1,698,666 | 1,698,666 | Sí      |
| silver  | silver_cuarentena         | 12,336    | 12,336    | Sí      |
| silver  | silver_abordajes          | 1,647,569 | 1,647,569 | Sí      |
| silver  | padron_vigente            | 22,462    | 22,462    | Sí      |
| silver  | silver_padron_scd2        | 28,421    | 28,421    | Sí      |
| gold    | fct_abordaje              | 1,647,569 | 1,647,569 | Sí      |
| gold    | fct_trayecto_metroriel    | 295,511   | 295,511   | Sí      |
| gold    | fct_padron_diario         | 8,612     | 8,612     | Sí      |
| gold    | dim_usuario               | 70,380    | 70,380    | Sí      |

Las 52 tablas están en evidencia/comparacion-corridas.csv.

### Rendimiento medido

| Etapa                                     | Corrida 1 (s) | Corrida 2 (s) |
|-------------------------------------------|---------------|---------------|
| Bronze batch                              | 1.39          | 0.24          |
| Bronze CDC                                | 0.22          | 0.04          |
| Bronze streaming (simulado)               | 12.53         | 0.10          |
| Vaciar staging                            | 0.03          | 0.06          |
| dbt build (modelos + 108 pruebas)         | 47.99         | 35.41         |
| Consulta del tablero (modo × zona × hora) | 23.5 ms       | 31.7 ms       |

| Capa             | Tamaño en disco |
|------------------|-----------------|
| Archivos crudos  | 136.8 MB        |
| Bronze (Parquet) | 31.3 MB         |

|                                     |        |
|-------------------------------------|--------|
| Warehouse (staging + silver + gold) | 499 MB |
|-------------------------------------|--------|

El archivo de DuckDB crece un poco en la segunda corrida, pero no es porque se dupliquen datos (los conteos son iguales): DuckDB no libera el espacio de las tablas que dbt reemplaza.