Gobernanza y reproducibilidad

RED METROPOLITANA · FASE 3

Integrantes

Yasmely Dubraska Fariñas Aldana - 1329223
Jose Rodrigo Herrera Muralles - 1042619
Walter José Herrera Salvatierra - 1109722

Documento de apoyo para la entrega y defensa. Reglas verificadas contra el proyecto ejecutado el 12 de octubre de 2026. Período de datos: 01/06 al 15/07/2026.

Resultado verificable

Evidencia	Resultado
Diccionario Gold	91 campos en 9 tablas, con tipo, significado, fuentes y transformación SQL.
dbt build	39 modelos + 3 seeds + 66 pruebas: 108 resultados correctos.
Idempotencia	52 tablas comparadas; cero diferencias entre las corridas.
Fase 2 completa	7 hojas, 3 dashboards y filtro por sistema; recomendación de 2 páginas; features de 70,380 usuarios.
Documentación dbt	Catálogo, manifest y grafo. Copias de entrega saneadas para retirar la sal.
Historial Git	Commits previos reales; formalización documental actual, sin inventar una cronología.

Alcance y decisiones declaradas

La gobernanza formaliza la lógica que ya existe. Los responsables académicos fueron confirmados por el usuario y se asignan por dominio. Acceso y retención son políticas propuestas: el prototipo local no las automatiza.

Archivos de consulta

README_FASE3.md organiza la entrega. Diccionario Gold en CSV, JSON y Markdown. Grafo en linaje_dbt/static_index.html. README_FASE2.md reúne recomendación, features y corte. Seguridad: PDF de una página.

3.1 Definiciones compartidas

Métrica	Contrato oficial
Abordaje	Validación limpia de entrada. TM incluye transbordo; TU estados 1/2/3; MR entrada; AM cabina. SUM(cantidad_abordajes).
Viaje de la red	El indicador comparable es abordaje, no viaje puerta a puerta. MR completo se analiza en su hecho separado.
Usuario activo	Identidad con al menos un abordaje válido en [inicio, fin), hora local. COUNT(DISTINCT usuario_sk) en el hecho filtrado.
Multimodalidad	Más de un sistema usado durante el mismo período. No confundir con dim_usuario.es_multisistema ni con transbordos encadenados.
Cobertura	Estaciones presentes en el catálogo de los 26 territorios. Ausencia en catálogo no demuestra ausencia de todo transporte real.
Hora pico	Día hábil y 06:00-08:59 o 17:00-19:59; hábil excluye festivos configurados.
Importe y padrón	GTQ dentro de un hecho; evitar doble conteo MR. Tarjetas activas: stock al cierre, nunca sumar entre días.

Dueños por dominio

Dominio	Responsable propuesto
Zona y estación	Yasmely Dubraska Fariñas Aldana (1329223). Coordinación territorial.
Sistemas y operación	Jose Rodrigo Herrera Muralles (1042619). Coordinación de operadores.
Calendario y métricas	Jose Rodrigo Herrera Muralles (1042619). Analítica y métricas.
Identidad y privacidad	Walter José Herrera Salvatierra (1109722). Privacidad y custodia.
Padrón CDC y calidad	Walter José Herrera Salvatierra (1109722). Ingeniería y calidad.

Cambios requieren versión, motivo, impacto, autorización del dueño y revisión de otro integrante. Asignaciones académicas confirmadas; roles institucionales propuestos. Dos cálculos independientes del total deben coincidir para los mismos filtros: 1,647,569 abordajes en el período observado.

3.1 Calidad y métricas medidas

Conservación operativa: 1,698,666 eventos = 1,647,569 abordajes + 41,390 rechazos TU + 9,707 casos de cuarentena. CDC añade 2,629 incidencias: cuarentena total de 12,336.

Sistema	Motivo	Registros	% fuente
CDC	CDC_SIN_TARJETA	2,206	7.105%
CDC	CDC_UPDATE_SOBRE_BAJA	423	1.362%
MR	VIAJE_SIN_SALIDA	3,589	1.2%
TM	DUPLICADO_TORNIQUETE	1,115	0.307%
TU	PARADA_NULA	4,189	0.503%
TU	FECHA_FUTURA	814	0.098%

Reglas en orden de prioridad

Duplicado entre archivos; duplicado dentro del archivo; usuario nulo; parada nula; estación desconocida; fecha inválida; fecha futura frente a ingesta; MR sin salida; salida inconsistente; zona inválida; monto inválido; estado TU desconocido. Un solo motivo por registro: el primero que falla.

Tratamiento

Conservar fuente, registro crudo, motivo y explicación en cuarentena. El dueño de fuente investiga y corrige; no editar Gold para ocultar errores. Los estados TU 7 y 9 son rechazos operativos válidos, separados de cuarentena y excluidos de abordajes.

CDC aplicado

31,050 eventos del log: 28,421 aplicados y 2,629 en cuarentena. Aplicados: 10,003 altas, 14,646 cambios y 3,772 bajas. Tarjetas activas después: 19,110. El snapshot diario no sustituye al conteo de todas las operaciones del log.

Cobertura y usuarios

15 de 26 territorios con estaciones; 11 sin ellas. 70,380 usuarios observados, de los cuales 36,827 (52.33%) usaron varios sistemas. El catálogo de identidad cuenta 36,829 multisistema: son poblaciones diferentes.

3.1 Linaje auditable del tablero

El grafo se genera a partir del manifest de dbt, conservando dependencias entre fuentes Bronze, staging, CDC, Silver, seeds y Gold. El diccionario registra las transformaciones SQL de los 91 campos.

Fuente Tableau	Tablas Gold y origen
demanda.csv	fct_abordaje + dim_fecha + dim_tiempo + dim_sistema + dim_zona. Hecho: Silver abordajes e identidad; staging de cuatro operadores; archivos de validaciones, transacciones, viajes y cabina.
cobertura.csv	dim_zona: territorios conformados del seed y estaciones Silver de catálogos TM, TU, MR y AM. Conserva territorios con cero estaciones.
multimodalidad.csv	fct_abordaje + dim_sistema: agrupar hechos por usuario y contar sistemas efectivamente utilizados durante todo el período.
metroriel.csv	dim_zona + fct_abordaje + dim_sistema: izquierda sobre todos los territorios; comparar demanda TM/TU en y fuera de las cinco zonas del corredor.

Lectura de la evidencia

Abrir linaje_dbt/static_index.html y explorar el grafo. manifest.json, catalog.json y aristas_linaje.json permiten inspección técnica. linaje_tablero.md muestra dependencias por fuente y consultas_exportacion_tableau.json conserva el SQL de exportación.

Fuentes y archivos crudos

El control de ingesta conserva archivo/hash y las tablas Silver retienen _source_file. El grafo de dbt llega a las nueve fuentes Bronze; las evidencias de ingesta relacionan cada fuente con el archivo original. Calendario, sistemas y territorios usan seeds versionados, no eventos operativos.

Límites de interpretación

No existe un vínculo fiable entre AM y otros operadores; las identidades AM quedan separadas. Zona del evento procede de la estación, no de residencia. La comparación del corredor es territorial y no demuestra ahorro de tiempo ni capacidad.

3.2 Reproducibilidad y decisiones

Usar Python 3.12, requirements.txt y .env propio excluido de Git. Seguir el README: generador, dos corridas de flows/pipeline.py, herramientas/comparar.py y herramientas/ddl.py. Streaming simulado; Docker solo si se elige Kafka real.

Decisiones defendibles

Grano común de abordaje y hecho MR completo separado. Vincular TM/TU/MR por número normalizado bajo supuesto explícito de numeración común. AM independiente. Seudonimizar en Silver. Normalizar GTQ y hora local. Cuarentena sin pérdida silenciosa. CDC con SCD2. Fuentes independientes para el tablero por sus distintos granos.

Evidencia de ejecución

Etapa / indicador	Corrida 1	Corrida 2
bronze_batch (s)	1.85	0.54
bronze_cdc (s)	0.24	0.07
bronze_streaming (s)	12.45	0.23
vaciar_staging (s)	0.03	0.09
dbt_build (s)	91.72	51.43
SQL referencia (ms)	58.3	38.5
Crudos (MB)	137.07	137.07
Bronze (MB)	31.32	31.32
Warehouse combinado (MB)	490.22	716.71

La duración SQL es una consulta de referencia en DuckDB, no render de Tableau. Staging, Silver y Gold comparten archivo: los tamaños físicos se reportan combinados. Las filas son idénticas aunque el archivo aumente tras reconstrucción.

Condiciones para repetir

Preservar archivos, seeds, variables y sal. Cambiar la sal cambia seudónimos; cambiar período o identidad altera usuarios. La dimensión fecha está configurada para 2026. Prefect requiere conexión a su servidor local; no modificar el flujo para resolver problemas del entorno.

Historial y aprobación

El repositorio conserva commits previos reales; historial_git.txt los registra. Esta bitácora formaliza decisiones hoy, sin inventar una documentación anterior al código. Cambios futuros deben quedar en commits reales, con motivo y validación.

Validación y alcance de la capa de características

La capa de características comprende 70,380 usuarios y 14 campos, derivados de Silver y del calendario de días festivos, sin depender de Gold. El corte exclusivo es el 16 de julio de 2026. El historial disponible abarca 45 días; por tanto, la ventana de análisis de 90 días cuenta con cobertura parcial.

Las seis pruebas de validación se completaron satisfactoriamente y ambas reconstrucciones produjeron contenido idéntico. El diccionario y las evidencias se encuentran en entregables/fase2. Las políticas de seguridad contemplan el acceso y la retención de estos datos; su aplicación aún no está automatizada en el prototipo.