Seguridad y datos personales - Fase 3

Yasmely Dubraska Fariñas Aldana - 1329223
Jose Rodrigo Herrera Muralles - 1042619
Walter José Herrera Salvatierra - 1109722

Datos sintéticos del curso. Política declarada para la propuesta de Agencia.

1. Credenciales y secretos

PSEUDO_SALT se guarda en .env, excluido de Git; .env.example no contiene valores reales. Gold y features no incluyen la sal. Las copias entregadas de dbt docs eliminan la sal del SQL compilado; dbt/target puede contenerla y no se debe compartir. En producción, custodiar y rotar secretos fuera del repositorio, con migración de identidades.

2. Seudonimización antes de Gold

Silver calcula usuario_sk con MD5(sal + persona_id). Gold omite tarjeta y persona_id; las features también. Esto es seudonimización, no anonimización: estación, horario y patrones siguen siendo sensibles. Para producción se propone HMAC-SHA-256 con llave protegida. Tableau contiene agregados; features_usuario.csv contiene detalle por usuario y requiere acceso restringido. AM conserva su identidad separada.

3. Quién puede ver qué

Analista de movilidad: agregados Gold/Tableau. Operador: su información y calidad. Ciencia de datos: features seudonimizadas para entrenamiento autorizado, sin mapa de identidad. Auditor de fraude: detalle por caso con autorización, plazo y registro. Custodio de identidad: Silver y correspondencia con tarjetas, separado del analista. Ingeniería: mínimo privilegio. Privacidad autoriza excepciones. Walter es responsable académico de identidad/privacidad; Jose Rodrigo, de analítica; Yasmely, de territorio. DuckDB local no aplica estos roles; son políticas propuestas.

4. Retención y justificación

Propuesta: crudos/Bronze y cuarentena, 90 días para conciliar y corregir; detalle individual Silver/Gold, features e identidad, 180 días para investigar y comparar períodos; agregados sin identificación, 24 meses para planificación; respaldos del detalle, 30 días adicionales. Al vencer, borrar o agregar; excepciones autorizadas con vencimiento. El prototipo no purga automáticamente. Los CSV de fase 1 versionados contienen datos sintéticos; en producción, excluir detalle individual de Git y usar almacenamiento restringido.